

CIIC5015: Artificial Intelligence

University of Puerto Rico at Mayaguez

Students: Luis Enrique Hualparimachi Saire and Paola J. Lizana Vasquez

FINAL EXAM

Repository: <https://github.com/luiseh/AttentionUsingTransformer.git>

Task 1:

```
(ciic5015) D:\Phd_class\CIIC5015\finalexam\AttentionUsingTransformer>python models.py
Input shape: torch.Size([2, 8, 16])
Output shape: torch.Size([2, 8, 16])
Shape test Passed
```

Task 2:

```
[Running] python -u "c:\Users\Paola\Documents\AttentionUsingTransformer\gpt_model.py"
Transformer_Block shape test passed
GPT logits shape test passed
GPT gradient test passed
All shape tests passed!
```

```
class Transformer_Block(nn.Module):
    def __init__(self, layer_size):
        super().__init__()
        self.attention = AttentionBlock(layer_size)
        self.norm1 = nn.LayerNorm(layer_size)
        self.ff = nn.Linear(layer_size, layer_size)
        self.norm2 = nn.LayerNorm(layer_size)

    def forward(self, x):
        attn_out = self.attention(x)
        x2 = attn_out + x
        x3 = self.norm1(x2)
        ff_out = torch.relu(self.ff(x3))
        x5 = ff_out + x3
        return self.norm2(x5)

class GPT(nn.Module):
    def __init__(self, vocab_size=100, layer_size=16, num_blocks=2):
        super().__init__()
        self.embedding = nn.Embedding(vocab_size, layer_size)
        self.blocks = nn.ModuleList(
            [Transformer_Block(layer_size) for _ in range(num_blocks)]
```

```

)
self.norm = nn.LayerNorm(layer_size)
self.output_proj = nn.Linear(layer_size, vocab_size)

def forward(self, idx):
    x = self.embedding(idx)
    for block in self.blocks:
        x = block(x)
    x = self.norm(x)
    logits = self.output_proj(x)
    return logits

def generate(self, idx, max_new_tokens, block_size):
    for _ in range(max_new_tokens):
        idx_cond = idx[:, -block_size:]
        logits = self(idx_cond)
        logits = logits[:, -1, :]
        probs = torch.softmax(logits, dim=-1)
        next_idx = torch.multinomial(probs, num_samples=1)
        idx = torch.cat((idx, next_idx), dim=1)
    return idx

```

Task 3:

- The last 10 lines of your training loss table and a 5–10-line sample of generated text from the trained model.

Ejecución del baseline mostrado en la guía.

```

(CIIC5015) D:\Phd_class\CIIC5015\finalexam\AttentionUsingTransformer>python train_gpt.py
step    loss
1       4.7243
300     2.7795
600     2.5524
900     2.4935
1200    2.4451
1500    2.4573
1800    2.4544
2100    2.4556
2400    2.4748
2700    2.4151
3000    2.4278

Generated sample:
e Mfof swe
QFthigeraf brsher, tewing hevlll mar couchto s eeangh segr werdir hashers sas.
Nomeed s, seaved ale,

Heardysset; our s An, Another ayipifo ird l hik padg camewe l gha yexm s tel cu fabrk'de ankne s why wicotere s dlasta th
e'
hern wed
Anlfat armere bund thin whald ngint te te, tot fiban bowoutwonges bur ong d bertce airer m pepan vethowistha's, may ty
a Pumyowald to m hingo mpe,
To r anthacisirrchemezan airs akist ha wive
TE n trk ay: oin ompave, mimala the hesacis pr ckllin Mese, b

```

```
[Running] python -u "c:\Users\Paola\Documents\AttentionUsingTansformer\train_gpt.py"
step    loss
1      4.7545
300    2.7607
500    2.5611
900    2.5021
1200    2.4764
1500    2.4514
1800    2.4626
2100    2.4478
2400    2.5070
2700    2.4094
3000    2.3615

Generated sample:
    e, dde, arecar hiv_.

Bus swes, ame ton havestour I he? h, br t.

whoftar too baldgerispim d me sirsaknghofueent g errilock y f amor,
fint monengr d oou, eanearneis t fie,
Ans, athe. s.

AMAten reit r
sts, d tendor aeshe-; t medidoruo cwon mar sppes tlla arse s thimbe whullond oo arar t on hechors mikn s oncelig boffen oon whe s otifous s alileses?
Meck w, h merg, s,
I y ararthoppe ry t suler nd wad at-erdeassthe n! ant s yougrieyowe Enk tourd h e.

TKWEle nimy savelaveng othy.
VGOWues mear
```

- Describe your corpus choice. Why did you choose that corpus?

Se eligió la data de “Shakespeare’s Complete Works”, porque es un texto amplio, el cual se encuentra estructurado y es un dominio público. Este es apropiado ya que contiene muchos caracteres que ayudarán al GPT que estamos probando. Vemos que tiene estas características:

- Diálogos
- Nombres
- Signos de puntuación
- Estructura bien definida (Poesía)
- Patrones repetitivos
- Saltos de líneas

Así se podrá efectuar el análisis de caracteres anteriores relevantes para predecir los futuros. Donde será importante para procesar y comparar cada posición, esto es fundamental para que el modelo prediga letras previas, espacios, límite de palabras o patrones largos como frases.

- Comment on the observed changes for larger values of N_LAYERS, LAYER_SIZE, or MAX_ITERS

Cuando incrementamos los valores N_LAYERS, LAYER_SIZE o MAX_ITERS, notamos que el modelo base en la tabla dada produjo pérdidas más altas y generó

un texto ruidoso, con ciertas características de estructura, espacios y signos entre palabras.

Cuando hicimos la modificación de `N_LAYERS`, mejoró en torno a los bloques del Transformer. Esto permitió mejorar los caracteres mediante Self-attention y feed-forward, dando paso a ver caracteres anteriores.

Cuando hicimos la modificación de `LAYERS_SIZE`, mejoró en torno a la calidad de los embeddings, queries, keys y values. Ayudo en la mejor representación de patrones de texto.

Cuando hicimos la modificación de `MAX_ITERS`, mejoró en torno a la capacidad del modelo; se podría decir que entrenarlo por más etapas podría dar mejores resultados, pero tampoco podría ser muy extendida en tiempo, ya que podría tener errores, ya sea por capacidad o por overfitting.

Obtuvimos un mejor resultado cuando juntamos todas estas modificaciones, ya que fue una fusión de lo mencionado anteriormente. Se notó que los fragmentos eran más reconocibles, con un mejor uso de los signos y una mayor distinción de los nombres. Lo más importante que se asimilaba a la estructura de la data de Shakespeare. Con esto concluimos que un transformer con mayores capacidades puede aprovechar mejor el algoritmo de self-attention, pero esto requerirá más tiempo de entrenamiento y costos computacionales.

Adjuntamos una captura de pantalla con la actualización de los valores.

```
3000    2.0801
3300    2.0328
3600    1.9915
3900    1.9865
4200    2.0262
4500    1.9911
4800    1.9142
5100    1.9649
5400    1.9601
5700    1.9783
6000    1.9031

Generated sample:
    fbagulere wind! Dukndwers heary thy dees
Seneer's scizirve's:
My florm's; the in you, pput prised sed streeat?

ANTH.
Not rimes thre pare the Kelsemes, begy;
What, whorid the doner of may willif de you ou rto,
Wheseave meo, and and hose mostere.

COLLPEWNROWAN.
I is t that trurife. [_aggrt Vexucceu, a that t texteursbah arkene I her to blaw._]

Enter o the wat sepporitin me. A dothlin, what empt's i so
Entexts theran is to awendy measternty theres.

GRSANITHE.
Thous that the and say trout is ne

(ciic5015) D:\Phd_class\CIIC5015\finalexam\AttentionUsingTansformer>
```